

# Reconocimiento de Patrones

Autores: José Luis Alba - Universidad de Vigo Jesús Cid - Universidad Carlos III de Madrid

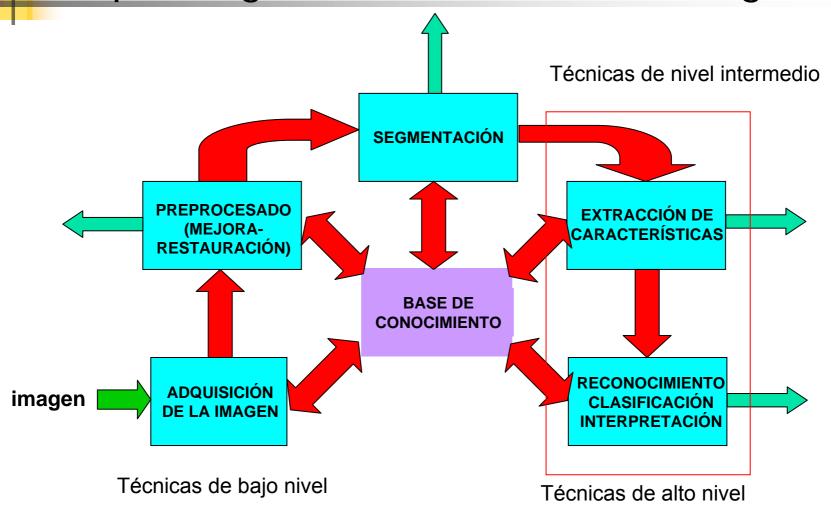
Ultima revisión: mayo de 2006



- Introducción
  - Esquema general del análisis de imágenes
  - Elementos del reconocimiento de patrones
- Patrones
  - Patrones vectoriales
  - Patrones estructurados
- Reconocimiento de patrones mediante funciones discriminantes
  - Flementos
  - Mínima distancia y Adaptación (Pattern Matching)
  - Clasificadores estadísticamente óptimos
  - Redes Neuronales Artificiales

# Introducción

Esquema general del análisis de imágenes





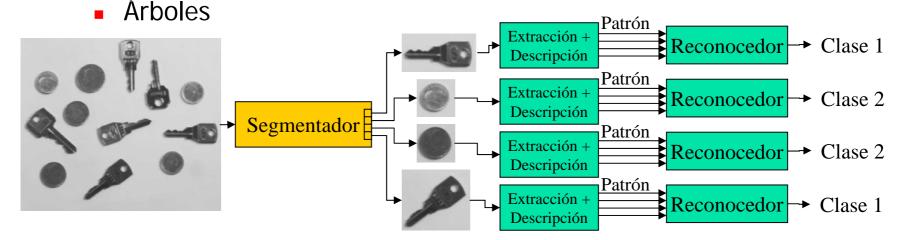
# Elementos del reconocimiento de patrones

#### **Patrones**

- Tras los procesos de segmentación, extracción de características y descripción, cada objeto queda representado por una colección (posiblemente ordenada y estructurada) de descriptores, denominada patrón.
- En los problemas de reconocimiento, cada patrón se supone perteneciente a una categoría o clase, c;
- El sistema de reconocimiento debe asignar cada objeto (de interés) a su categoría.
- Reconocimiento o clasificación: proceso por el que se asigna una "etiqueta", que representa una clase, a un patrón concreto.
- Clase: conjunto de entidades que comparten alguna característica que las diferencia de otras.
- Clase de rechazo: conjunto de entidades que no se pueden etiquetar como ninguna de las clases del problema
- <u>Extractor de características</u>: subsistema que extrae información relevante para la clasificación a partir de las entidades cuantificables
- <u>Clasificador</u>: subsistema que utiliza un vector de características de la entidad cuantificable y lo asigna a una de *M* clases
- Evaluación del error de clasificación: "error de clasificación", "tasa de error empírica", "tasa de rechazo empírica", "conjunto de datos independientes".
- <u>Falso rechazo (falso negativo) y falsa aceptación (faso positivo):</u> para problemas de 2 clases estas definiciones reflejan la importancia de una decisión contra la opuesta. El sistema de clasificación se puede "sintonizar" para que trabaje ponderando un tipo de error sobre el otro

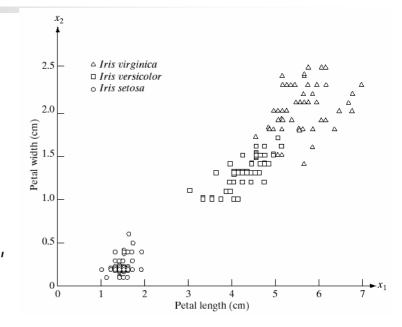
# **Patrones**

- Para el reconocimiento automático, es importante que
  - Patrones que describen objetos de una misma clase, presenten características similares.
  - Patrones que describen objetos de diferentes clases presenten características diferenciadas.
- Tipos de patrones:
  - Vectores:  $\mathbf{x} = (x_1, x_2, ..., x_n)^T$
  - Cadenas



## Patrones vectoriales

- Ejemplo: Clasificación de tipos de Iris (flores).
  - Tres categorías
  - Patrones bidimensionales
    - Longitud del pétalo
    - Anchura del pétalo
  - Los descriptores utilizados sirven para discriminar iris setosa de las otras dos, pero no para discriminar entre iris virginica e iris versicolor







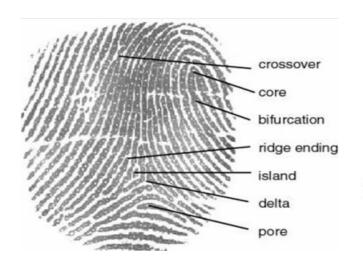


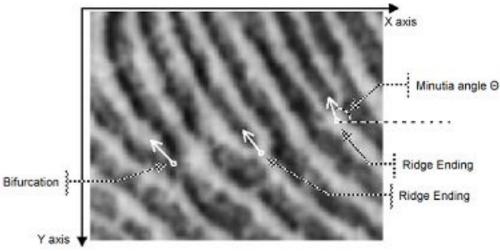
http://www.et.ethz.ch/eTutorials/evim/dateien/u3/irisbilder.htm

## Patrones estructurados

- Codifican relaciones (espaciales o de otro tipo) entre componentes del objeto o descriptores.
- Ejemplo:
  - Reconocimiento de huellas dactilares
    - Los algoritmos de reconocimiento suelen basarse en la detección de las *minucias* (minutiae), las cadenas (ridges) que forman, y su relación entre ellas

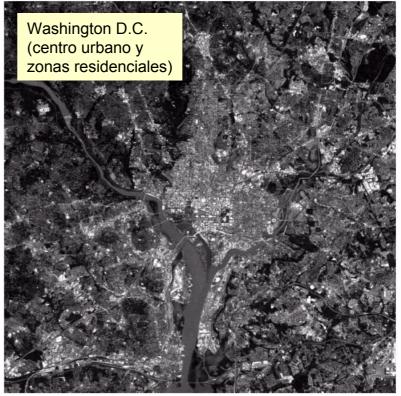


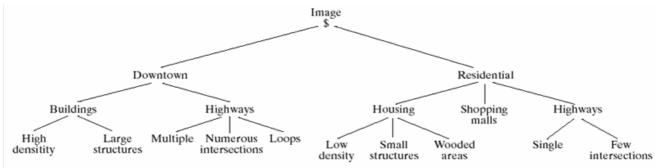




# Ejemplo:

- Imagen de satélite
- Descripción en árbol
  - Cada rama codifica una relación "compuesto de"

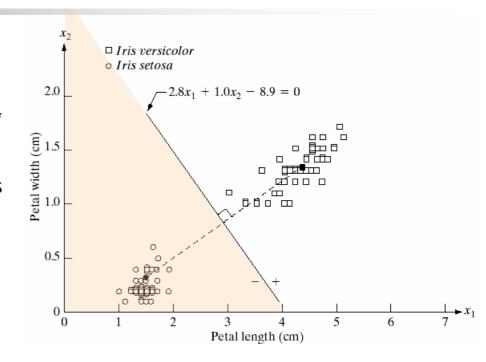


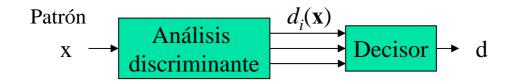


# Reconocimiento mediante funciones discriminantes

#### Elementos:

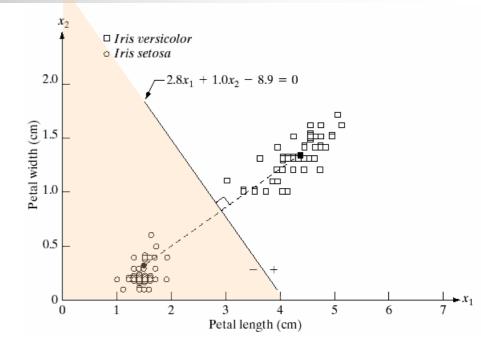
- Función discriminante, d<sub>i</sub>(x):
  - Mide la relevancia de la clase  $c_i$  para el patrón  $\mathbf{x}$ .
- Región de decisión, R<sub>i</sub>:
  - El conjunto de todos los puntos del espacio que el reconocedor asigna a la clase c<sub>i</sub>
- Frontera de decisión:
  - Separa regiones de decisión.
- Decisor:
  - Típicamente (aunque no siempre), seleccionan la clase de mayor (o menor) valor de la función discriminante d(x).

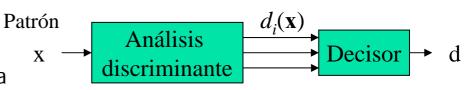






- Conjunto de entrenamiento:
  - $\{\mathbf{x}^{(k)}, c^{(k)}, k=1,...,K\}$
  - Conjunto de patrones etiquetados (cuya clase es conocida)
- Algoritmo de entrenamiento:
  - Es un conjunto de reglas de ajuste de los parámetros de las funciones discriminantes d<sub>i</sub>(x,w<sub>i</sub>)
- Conjunto de prueba (test)
  - Conjunto de patrones etiquetados NO utilizados durante el entrenamiento.
  - Sirven para evaluar el rendimiento del clasificador.
  - Generalización: capacidad para clasificar correctamente patrones no utilizados durante el entrenamiento.







- Adaptación (*Pattern Matching*)
  - Representan cada clase mediante un patrón prototipo.
    - Clasificador de mínima distancia
    - Adaptación por correlación
- Clasificadores estadísticamente óptimos
  - Se fundamentan en la Teoría de la Decisión Estadística
    - Clasificador bayesiano para clases gausianas
- Redes neuronales
  - Se fundamentan en la teoría del aprendizaje estadístico
    - Perceptrón para dos clases
    - Perceptrón multicapa

# Reconocimiento mediante funciones discriminantes Clasificador de mínima distancia

- Se caracteriza por las funciones discriminantes  $d_i(\mathbf{x}) = \|\mathbf{x} \mathbf{m}_i\|^2$ 
  - siendo **m**, un patrón prototipo de la clase i.
- Asignan la muestra a la clase "más próxima"  $d = \arg\min_{i} \{d_i(\mathbf{x})\}$
- Dado que  $d_i(\mathbf{x}) = (\mathbf{x} \mathbf{m}_i)^T (\mathbf{x} \mathbf{m}_i) = \mathbf{x}^T \mathbf{x} 2\mathbf{m}_i^T \mathbf{x} + \mathbf{m}_i^T \mathbf{m}_i$

se puede prescindir del primer término, que no depende de la clase, de modo que las funciones discriminantes

$$d_i(\mathbf{x}) = -2\mathbf{m}_i^T \mathbf{x} + \mathbf{m}_i^T \mathbf{m}_i$$

son equivalentes a las anteriores.

Las fronteras de decisión del clasificador de mínima distancia son de la forma  $d_i(\mathbf{x}) = d_i(\mathbf{x})$ 

es decir, 
$$-2(\mathbf{m}_{i}-\mathbf{m}_{i})^{T}\mathbf{x}+\mathbf{m}_{i}^{T}\mathbf{m}_{i}-\mathbf{m}_{i}^{T}\mathbf{m}_{i}=0$$

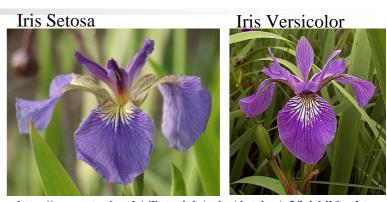
que son hiperplanos



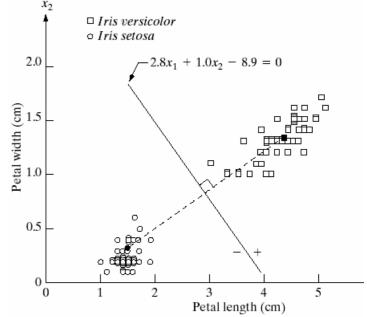
- El prototipo m<sub>i</sub> que caracteriza a cada clase puede obtenerse mediante extracción de características sobre una imagen previamente etiquetada.
- También puede obtenerse a partir de una colección de patrones etiquetados:

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{j=1}^{N_i} \mathbf{x}_{i,j}$$

siendo  $\{\mathbf{x}_{i,j}\}$  los patrones de la clase i del *conjunto de entrenamiento.* 

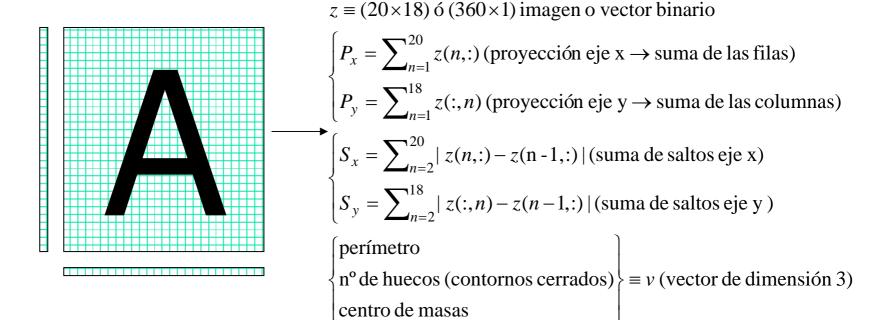


http://www.et.ethz.ch/eTutorials/evim/dateien/u3/irisbilder.htm

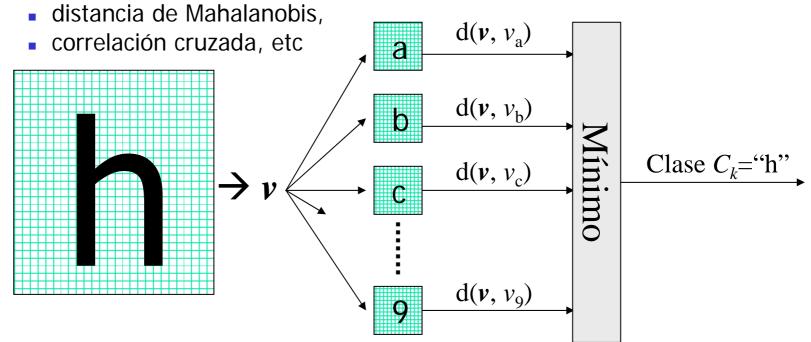




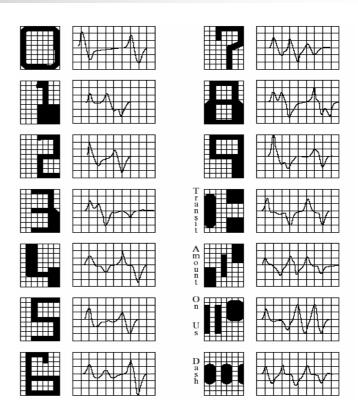
- Clases:  $C_k$ : {A,B,...,a,b,...0,1,2,...a,b,...a,b,...a,b,...a,b,...a,b,...}
- Clase de rechazo: Cr:{!,",\$,%,&,/,(,),=,?,¿,∼,×...}
- Extractor de características:



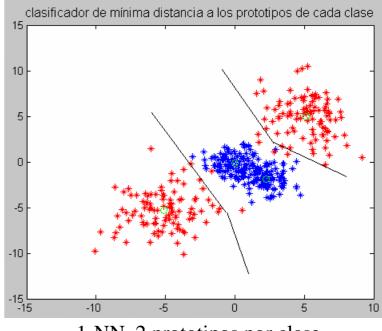
- El reconocedor de caracteres asigna el vector "v" a la clase que más se "parece".
- Medidas de similitud:
  - distancia euclidea
  - distancia de Hamming,



- Ventajas del clasificador de mínima distancia
  - Simplicidad
  - Facilidad de ajuste
- Inconvenientes:
  - Sólo funciona cuando las clases forman nubes poco dispersas y bien separadas
    - Ejemplo: fuente de caracteres E-13B de la American Bankers Association, especialmente diseñada para facilitar el reconocimiento automático.
    - La signatura refleja la derivada de la cantidad de negro en dirección vertical, al mover un scanner de izquierda a derecha
    - El muestreo en los puntos de la cuadrícula proporciona información con suficiente capacidad discriminante



- Extensiones del clasificador de mínima distancia:
  - Permiten obtener fronteras de clasificación más complejas, y modelar categorías que no quedan adecuadamente representadas por su media.
  - k-NN (Nearest Neighbour):
    - Cada clase, C<sub>j</sub>, se caracteriza por una colección de prototipos, m<sub>jj</sub>
    - Cada patrón, x, se asigna á la clase mayoritaria de los k prototipos más próximos
    - Selección de prototipos:
      - Cada muestra de entrenamiento, un prototipo.
      - Prototipos obtenidos mediante un algoritmo de agrupamiento (como el k-means –ver presentación de Análisis de imágenes-).



1-NN, 2 prototipos por clase

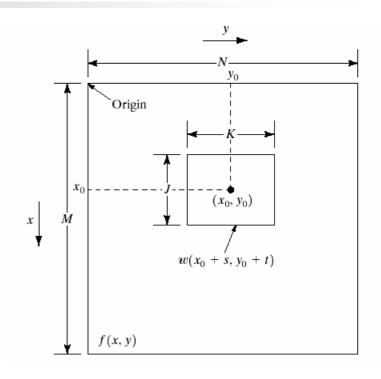
# Reconocimiento mediante funciones discriminantes Adaptación por correlación

- Los métodos de adaptación por correlación también se basan en la comparación de la imagen a clasificar con una o varias imágenes patrón que caracterizan a cada clase.
- Es equivalente al de mínima distancia si los patrones están normalizados:

$$d_i(\mathbf{x}) = -2\mathbf{m}_i^T \mathbf{x} + \mathbf{m}_i^T \mathbf{m}_i \Rightarrow d_i'(\mathbf{x}) = \mathbf{m}_i^T \mathbf{x}$$

- Utilizan medidas de similitud basadas en correlaciones:
  - Correlación:

$$c(x,y) = \sum_{s} \sum_{t} f(s,t) w(x+s,y+t)$$

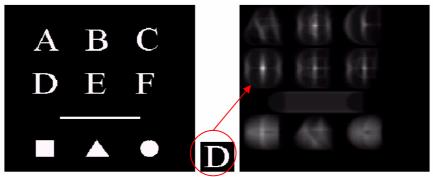


#### Coeficiente de correlación:

• Proporciona una medida invariante frente a cambios en la amplitud.  $\sum \sum (f(s,t) - \bar{f}(s,t))(w(x+s,y+t) - \overline{w})$ 

amplitud. 
$$c(x,y) = \frac{\sum_{s} \sum_{t} (f(s,t) - \bar{f}(s,t))(w(x+s,y+t) - \overline{w})}{\left[\sum_{s} \sum_{t} (f(s,t) - \bar{f}(s,t))^{2}\right]^{1/2} \left[\sum_{s} \sum_{t} (w(x+s,y+t) - \overline{w})^{2}\right]^{1/2}}$$

donde los promedios de w se calculan sobre todo el patrón (habitualmente más pequeño que la imagen), mientras que los de f se calculan sobre la región en torno al píxel del tamaño del patrón.

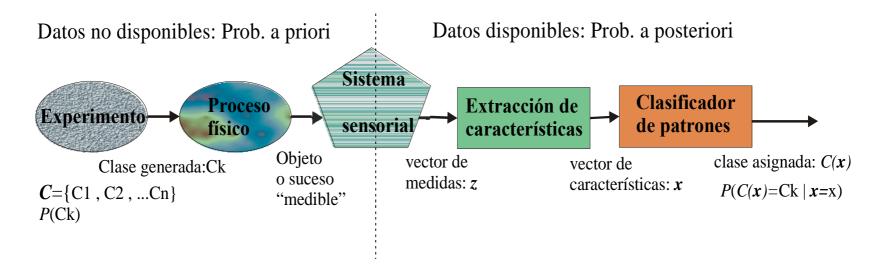


 Otras normalizaciones (para obtener invarianzas respecto a cambios de escala u orientación) son posibles, pero a mayor complejidad

# Reconocimiento mediante funciones discriminantes Clasificadores estadísticamente óptimos

#### Introducción:

 El mecanismo de generación de patrones se puede representar de forma probabilística:



#### Reconocimiento mediante funciones discriminantes

# Clasificadores estadísticamente óptimos

#### Caracterización estadística

- La teoría de la decisión parte del supuesto de que los patrones son realizaciones independientes de un modelo probabilístico  $p(c,\mathbf{x})=P(c|\mathbf{x})$   $p(\mathbf{x})$ 
  - En general, en los problemas de reconocimiento de patrones tenemos clases mutuamente exclusivas y colectivamente exhaustivas, es decir:

$$\sum_{k=1}^{C} P(c_k) = 1$$

siendo C el número de clases.

- Elementos:
  - Los **costes**,  $L_{ij}$ : coste de asignar a  $c_j$  un patrón de la clase  $c_i$ .
  - El riesgo medio condicional de asignar un patrón a clase j :

$$r_{j}(\mathbf{x}) = \sum_{k=1}^{C} L_{kj} P(c_{k} \mid \mathbf{x})$$

#### Clasificador de mínimo riesgo

Será aquél basado en las reglas de decisión

$$i = \arg\min_{j} r_{j}(\mathbf{x}) = \arg\min_{j} \sum_{k=1}^{C} L_{kj} P(c_{k} \mid \mathbf{x})$$

aplicando la regla de Bayes

$$P(c_k \mid \mathbf{x}) = \frac{P(c_k) p_{x|c_k}(\mathbf{x} \mid c_k)}{p_x(\mathbf{x})}$$

se obtiene la expresión alternativa

$$i = \arg\min_{j} \sum_{k=1}^{C} L_{kj} p(\mathbf{x} \mid c_{k}) P(c_{k})$$

- Clasificador de mínima probabilidad de error
  - Se obtiene dando idéntico valor a todos los errores:  $L_{ii} = 1 \delta_{ii}$

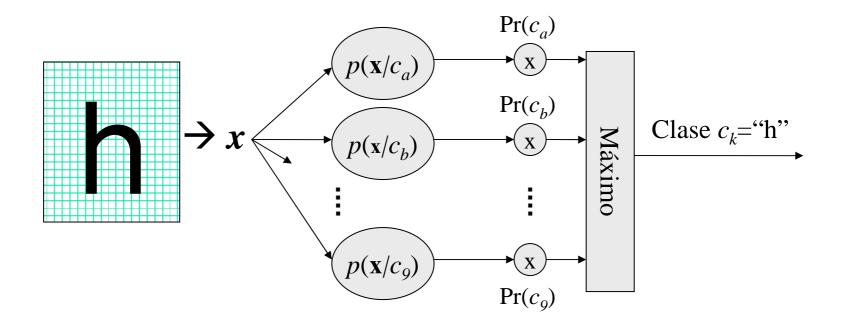
$$r_j(\mathbf{x}) = \sum_{k=1}^C P(c_k \mid \mathbf{x}) - \sum_{k=1}^C \delta_{kj} P(c_k \mid \mathbf{x}) = 1 - P(c_j \mid \mathbf{x})$$

(que es la probabilidad de error)

$$i = \arg\min_{j} \{1 - P(c_j \mid \mathbf{x})\} = \arg\max_{j} \{P(c_j \mid \mathbf{x})\}$$

(decisión MAP (*máximo a posteriori*), que selecciona la categoría más probable, dada la observación)

 Ejemplo: Reconocimiento de caracteres mediante un decisor MAP





## Diseño del clasificador Bayesiano

- En la mayoría de las aplicaciones prácticas, no se conocen  $P(c_k)$ ,  $p(\mathbf{x}|c_k)$  ni  $P(c_k|\mathbf{x})$ .
- En tal caso, deben estimarse a partir de un conjunto de entrenamiento.
- Se presentan dos alternativas:
  - Estimar  $P(c_k|\mathbf{x})$ , o bien
  - Estimar  $P(c_k)$  y  $p(\mathbf{x}|c_k)$ 
    - $P(c_k)$ : puede suponerse constante (categorías equiprobables) o estimarse como la proporción de observaciones etiquetadas y no etiquetadas.
    - $p(\mathbf{x}|c_k)$ : hay muchos métodos. Los más sencillos suponen que las distribuciones son gausianas. La estimación se reduce a los parámetros de media y covarianzas.

## Clasificador bayesiano para clases gausianas

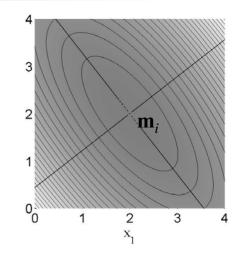
Se caracteriza por

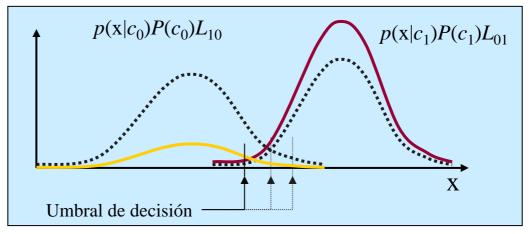
$$p(\mathbf{x} \mid c_i) = \frac{1}{(2\pi)^{N/2} |\mathbf{V}_i|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mathbf{m}_i)^T \mathbf{V}_i^{-1} (\mathbf{x} - \mathbf{m}_i) \right]$$

#### siendo

$$\mathbf{m}_{i} = E\{\mathbf{x} \mid c_{i}\} \approx \frac{1}{N_{i}} \sum_{d^{(k)} = c_{i}} \mathbf{x}^{(k)}$$

$$\mathbf{V}_{i} = E\left\{\left(\mathbf{x} - \mathbf{m}_{i}\right)\left(\mathbf{x} - \mathbf{m}_{i}\right)^{T} \mid c_{i}\right\} \approx \frac{1}{N_{i}} \sum_{d^{(k)} = c_{i}} \left(\mathbf{x}^{(k)} - \mathbf{m}_{i}\right)\left(\mathbf{x}^{(k)} - \mathbf{m}_{i}\right)^{T}$$



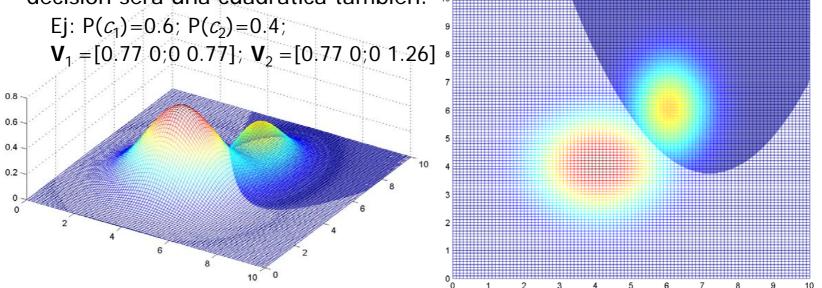


Función discriminante: suele utilizarse el logaritmo:

$$d_i(\mathbf{x}) = \ln(p(\mathbf{x} \mid c_i)P(c_i)) = -\frac{N}{2}\ln(2\pi) - \frac{1}{2}\ln|\mathbf{V}_i|^{1/2} - \frac{1}{2}(\mathbf{x} - \mathbf{m}_i)^T \mathbf{V}_i^{-1}(\mathbf{x} - \mathbf{m}_i) + \ln(P(c_i))$$

$$\equiv -\frac{1}{2}\ln|\mathbf{V}_i|^{1/2} - \frac{1}{2}(\mathbf{x} - \mathbf{m}_i)^T \mathbf{V}_i^{-1}(\mathbf{x} - \mathbf{m}_i) + \ln(P(c_i))$$

→ Es una forma cuadrática para cada clase, con lo que la frontera de decisión será una cuadrática también.



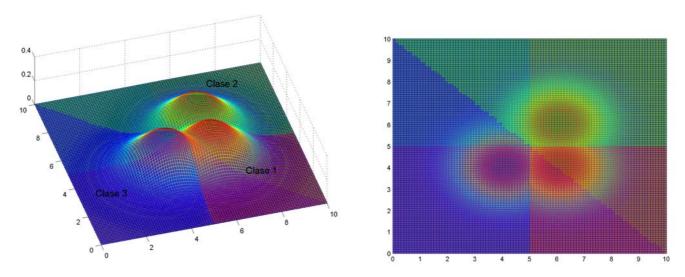


$$d_i(\mathbf{x}) \equiv \mathbf{m}_i^T \mathbf{V}^{-1} \mathbf{x} - \frac{1}{2} \mathbf{m}_i^T \mathbf{V}^{-1} \mathbf{m}_i + \ln(P(c_i))$$

y, por tanto, es una función discriminante lineal

Si, finalmente, las matrices son proporcionales a la identidad, resulta  $d_i(\mathbf{x}) = \mathbf{m}_i^T \mathbf{x} - \frac{1}{2} \mathbf{m}_i^T \mathbf{m}_i$ 

que coincide con la función discriminante del clasificador de mínima distancia.



Ejemplo: clasificación de terrenos en imágenes multiespectrales.

- Las Imágenes multiespectrales codifican información en varias bandas, sensibles a diferentes longitudes de onda del espectro electromagnético.
- Los clasificadores bayesianos se han mostrado efectivos para clasificación de terrenos en muchos tipos de imágenes

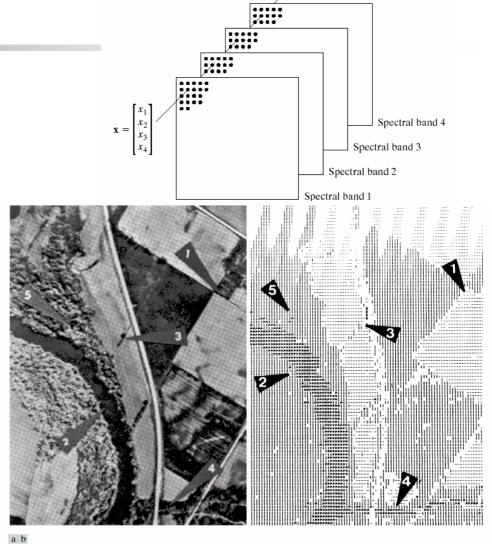
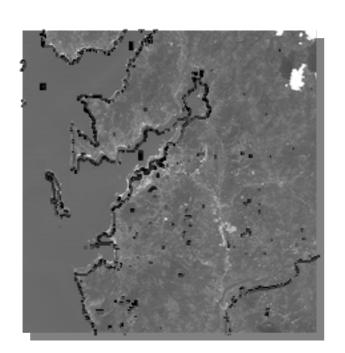
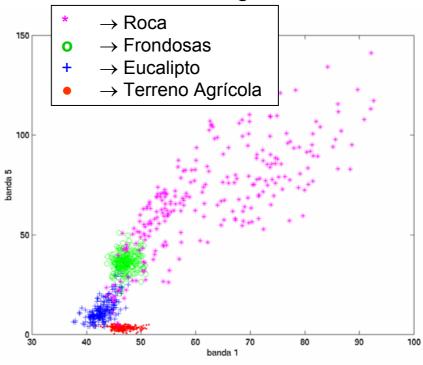


FIGURE 12.13 (a) Multispectral image. (b) Printout of machine classification results using a Bayes classifier. (Courtesy of the Laboratory for Applications of Remote Sensing, Purdue University.)



- Con frecuencia, no es realista (los datos no tienen una distribución gausiana)
  - Ejemplo: Diagrama de dispersión de las bandas 1 (azul) y 5 (infrarrojo cercano) de un conjunto de datos pertenecientes a una imagen Landsat (7 bandas) de las Ría de Vigo.







### Clasificador bayesiano para mezclas de gausianas

• Modelo más general:  $\mathbf{x} \in C_k$  se asume con fdp compuesta por una mezcla de gausianas de medias  $\mu_{kl}$ , covarianza  $\mathbf{V}_{kl}$  y factores de mezcla  $\mathbf{w}_l$  es decir:

$$p(\mathbf{x} \mid c_k) = \sum_{l=1}^{L} w_{kl} p(\mathbf{x} \mid l, c_k) = \sum_{l=1}^{L} w_{kl} \frac{1}{(2\pi)^{p/2} |\mathbf{V}_{kl}|^{1/2}} \exp\left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_{kl})^T \mathbf{V}_{kl}^{-1} (\mathbf{x} - \boldsymbol{\mu}_{kl})\right]$$

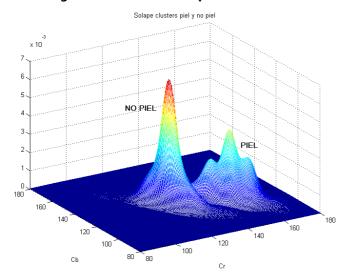
- La estimación ML de los parámetros  $\mathbf{w}_l$ ,  $\mu_{kl}$  y  $\Sigma_{kl}$  para cada clase se realiza de forma iterativa mediante un algoritmo conocido como Esperanza-Maximización (EM).
- El clasificador MAP responde a la expresión:

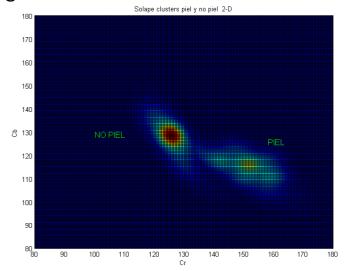
$$C(x) = \arg\max_{k} \{ P(C_k) p(x \mid C_k) \}$$

 Las fronteras de decisión son superficies hipercuádricas a tramos

### Ejemplo:

 Clasificación de piel/no piel en un espacio de color bi-dimensional (sin información de luminancia), modelando cada clase como una mezcla de gausianas y estimando parámetros con el algoritmo EM:









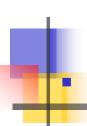
## Reconocimiento mediante funciones discriminantes Métodos basados en Teoría de la Decisión

# Redes Neuronales Artificiales

- Background
- Perceptrón para dos clases
  - Algoritmos de entrenamiento
    - Clases separables linealmente
    - Clases no separables linealmente

# Motivación:

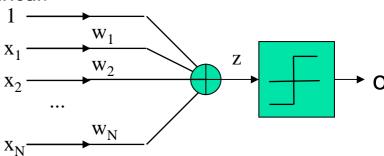
- El análisis previo pone de manifiesto que, para diseñar un clasificador estadísticamente óptimo a partir de un conjunto de datos de entrenamiento, pueden adoptarse tres estrategias:
  - Estimar  $P(c_k|\mathbf{x})$
  - Estimar  $P(\mathbf{x}|c_k)$  y  $P(c_k)$
  - Determinar una función discriminante que proporcione la frontera de decisión óptima.
- El término "redes neuronales" engloba a un conjunto de técnicas que proporcionan soluciones flexibles (adaptables a cada problema) para cada una de estas estrategias.



#### Perceptron para dos clases

Implementa la función discriminante lineal:

$$z = d(x) = w_0 + \sum_{i=1}^n w_i x_i = \mathbf{w}_e^T \mathbf{x}_e$$



 $\mathbf{W}_{0}$ 

Para un conjunto finito de muestras podemos hallar un vector de pesos apropiado buscando una solución de estas inecuaciones (para dos clases):

$$+ \mathbf{w}_{e}^{t} \mathbf{x}_{1j} > 0, \quad 1 \le j \le M_{1}$$
  
 $- \mathbf{w}_{e}^{t} \mathbf{x}_{2j} > 0, \quad 1 \le j \le M_{2}$ 

- ¿Cómo determinar los pesos?
  - → Algoritmo de entrenamiento: procedimiento recursivo que modifica el vector de pesos hasta que se cumplen las desigualdades:
  - Iniciar aleatoriamente los pesos
  - Presentar cada muestra al sistema de inecuaciones
    - Si bien clasificada no alterar pesos
    - Si mal clasificada alterar los pesos de forma conveniente

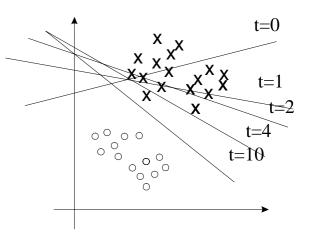


## Algoritmos de entrenamiento

- Clases separables linealmente
  - Regla del Perceptrón:

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} + \frac{\alpha}{2} \left[ d^{(k)} - o^{(k)} \right] \mathbf{x}^{(k)} \quad (0 < \alpha < 1); \quad con \quad d^{(k)}, o^{(k)} = \{-1; 1\}$$

- Si no hay error, no hay cambio
- Si hay error,  $\mathbf{w}^{(k+1)T} \mathbf{x}^{(k)}$  cambia en el sentido de corregir el error.
- Teorema de entrenamiento del perceptrón:
  - Si las clases son linealmente separables, la regla del perceptrón converge a una solución de cero errores en un número finito de pasos.



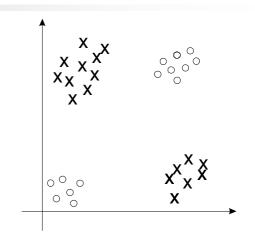


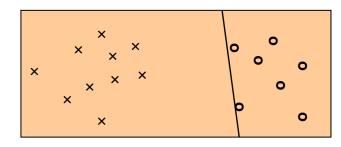
- En este caso, la regla del perceptrón no se detiene.
- Soluciones:
  - Discriminantes no lineales, pero lineales en los parámetros:

$$z = d(x) = w_0 + \sum_{i=1}^{n} w_i x_i + \sum_{i=1}^{n} w_i x_i^2$$

permiten obtener fronteras no lineales que obtengan soluciones de cero errores → perceptrón multicapa

- Variantes heurísticas, como el algoritmo del Bolsillo, que conserva en una memoria aparte (bolsillo) los pesos que han dado lugar a la secuencia de pasos de entrenamiento libre de errores más larga
- Inconvenientes de la Regla del Perceptrón:
  - Mala generalización:
    - aunque el problema sea intrínsecamente separable (para el clasificador usado), el algoritmo puede colocar la frontera en una posición inadecuada





- El ADALINE ("ADAptive LInear NEuron")
  - Tiene la misma arquitectura del Perceptrón, pero se entrena mediante un algoritmo de gradiente:

$$\mathbf{w}_{e}^{(k+1)} = \mathbf{w}_{e}^{(k)} - \alpha \nabla_{\mathbf{w}} J(\mathbf{w}_{e}^{(k)})$$

siendo  $J(\mathbf{w}_e)$  una función de coste. La más habitual es el error cuadrático:

$$J(\mathbf{w}) = \frac{1}{2N} \sum_{k=1}^{N} \left( d^{(k)} - \mathbf{w}_{e}^{(k)T} \mathbf{x}_{e}^{(k)} \right)^{2} \approx \frac{1}{2} E \left\{ \left( d^{(k)} - \mathbf{w}_{e}^{(k)T} \mathbf{x}_{e}^{(k)} \right)^{2} \right\}$$

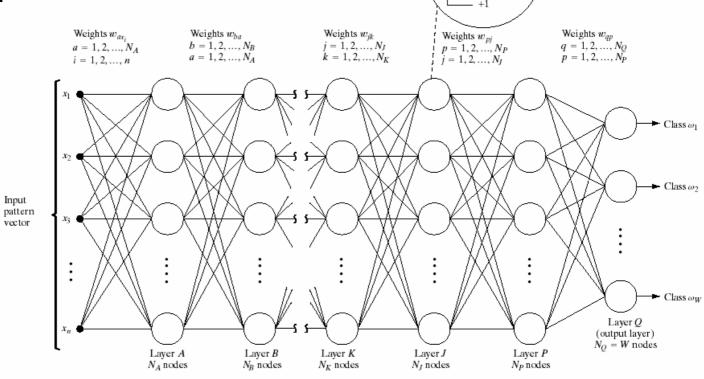
 En la versión estocástica (el algoritmo de Widrow-Hoff) se aplica el gradiente sobre una sola muestra, resultando

$$\mathbf{w}_{e}^{(k+1)} = \mathbf{w}_{e}^{(k)^{T}} + \alpha \left[ d^{(k)} - z^{(k)} \right] \mathbf{x}_{e}^{(k)} \quad (0 < \alpha < 1)$$

• Puede demostrarse que, para  $\alpha$  suficientemente pequeño, la regla del ADALINE converge (aunque no necesariamente a una solución de mínimo numero de errores).

# Perceptrón multicapa

Arquitectura básica



**FIGURE 12.16** Multilayer feedforward neural network model. The blowup shows the basic structure of each neuron element throughout the network. The offset,  $\theta_i$ , is treated as just another weight.

### El perceptrón multicapa es un aproximador universal.