

# ¿Qué son las redes neuronales artificiales? Aplicaciones realizadas en el ámbito de las adicciones

PALMER POL, A\*; MONTAÑO MORENO, J.J.\*\*

\* Prof. Titular del Departamento de Psicología. Universidad de las Islas Baleares.

\*\* Becario. Departamento de Psicología. Universidad de las Islas Baleares.

Enviar correspondencia a:

Alfonso Palmer Pol. Universidad de las Islas Baleares. Departamento de Psicología. Cra. de Valldemossa, km. 7,5. 07071 Palma (Baleares). Teléfono 971173432.

## Resumen:

En el presente trabajo, se introduce al lector en el campo de las redes neuronales artificiales (RNA) —características generales, arquitecturas, reglas de aprendizaje, ejemplos ilustrativos y aplicaciones generales—, y se realiza una revisión de las aplicaciones llevadas a cabo con esta tecnología en el campo de las conductas adictivas. Los resultados de las investigaciones demuestran la capacidad de las RNA para predecir el consumo de drogas, extraer las características prototípicas del sujeto adicto y seleccionar el tratamiento más adecuado en función de esas características. Aunque tales estudios son preliminares, los resultados se pueden considerar prometedores, perfilándose las RNA como un potente instrumento al servicio del profesional dedicado al campo de las conductas adictivas.

**Palabras clave:** *redes neuronales artificiales; adicción a las drogas; predicción; revisión bibliográfica.*

## Abstract:

In this paper, we introduce to the reader in the field of artificial neural networks (ANN) —general features, architectures, learning rules, illustrative examples and general applications—, and we review the applications carried out with this technology in the field of addictive behaviors. Results of research show the capacity of ANN in order to predict drug consumption, extract prototype characteristics of addicted subjects and choose the treatment most appropriate according to those characteristics. Although these studies are preliminary, the results can be qualified as very promising; so, ANN are a powerful tool for professional dedicated to field of addictive behaviors.

**Key words:** *artificial neural networks, drug addiction, prediction, bibliographic review.*

## INTRODUCCIÓN

El uso y abuso de sustancias comprende un conjunto de conductas complejas que son iniciadas, mantenidas y modificadas por una variedad de factores conocidos y desconocidos. El tipo de función o relación que se establece entre la conducta adictiva y los factores que la explican no se puede reducir a una simple relación lineal de “causa-efecto” (Buscema, 1997, 1998). Por tanto, si nos planteamos como objetivo la prevención y la predicción de este tipo de conductas, será necesario utilizar instrumentos capaces de manejar relaciones complejas o no lineales.

El reciente campo de la computación biológica —que comprende las redes neuronales artificiales, los algoritmos genéticos, las estrategias y programación evolutivas, los sistemas borrosos y la vida artificial (Pazos, 1996)—, en general, y las redes neuronales

artificiales (RNA) en particular, han demostrado su utilidad en la solución de problemas complejos. Así, las RNA han sido utilizadas satisfactoriamente en la predicción de diversos problemas en diferentes áreas de conocimiento —biología, medicina, economía, ingeniería y psicología— (Arbib, 1995; Simpson, 1995; Arbib, Erdi y Szentagothai, 1997); con buenos resultados respecto a los modelos derivados de la estadística clásica (Bonilla y Puertas, 1997; Duncan, 1997; French, Dawson y Dobbs, 1997; Jefferson, Pendleton, Lucas et al., 1997; Shekharan, 1997; Tommaso, Sciuricchio, Bellotti et al., 1997; Vohradsky, 1997; West, Brockett y Golden, 1997; De Lillo y Meraviglia, 1998; Jang, 1998; Waller, Kaiser, Illian et al., 1998). En el caso de las adicciones, estudios recientes, que se describen más adelante, demuestran la capacidad de las RNA para predecir el consumo de drogas, extraer las características prototípicas del sujeto adicto y

seleccionar el tratamiento más adecuado en función de esas características.

Con el presente trabajo nos proponemos introducir al lector, de una forma sencilla, en el campo de las RNA y revisar las aplicaciones llevadas a cabo con esta tecnología en el ámbito del estudio de las adicciones.

## REDES NEURONALES ARTIFICIALES

### Características generales

Las RNA son sistemas de procesamiento de la información cuya estructura y funcionamiento están inspirados en las redes neuronales biológicas (Hilera y Martínez, 1995). Consisten en un gran número de elementos simples de procesamiento llamados nodos o neuronas que están organizados en capas. Cada neurona está conectada con otras neuronas mediante enlaces de comunicación, cada uno de los cuales tiene asociado un peso. Los pesos representan la información que será usada por la red neuronal para resolver un problema determinado.

Así, las RNA son sistemas adaptativos que aprenden de la experiencia, esto es, aprenden a llevar a cabo ciertas tareas mediante un entrenamiento con ejemplos ilustrativos.

Mediante este entrenamiento o aprendizaje, las RNA crean su propia representación interna del problema, por tal motivo se dice que son autoorganizadas. Posteriormente, pueden responder adecuadamente cuando se les presentan situaciones a las que no habían sido expuestas anteriormente, es decir, las RNA son capaces de generalizar de casos anteriores a casos nuevos.

Esta característica es fundamental ya que permite a la red responder correctamente no sólo ante informaciones novedosas, sino también ante informaciones distorsionadas o incompletas.

En las RNA el tipo de procesamiento de la información es en paralelo, en el sentido de que muchas neuronas pueden estar funcionando al mismo tiempo. De hecho, nuestro cerebro está compuesto por unas  $10^{11}$  neuronas, las cuales operan en paralelo. Es ahí donde reside una parte fundamental de su poder de procesamiento. Aunque individualmente las neuronas sean capaces de realizar procesamientos muy simples, ampliamente interconectadas a través de las sinapsis (cada neurona puede conectarse con otras 10.000 en promedio) y trabajando en paralelo pueden desarrollar una actividad global de procesamiento impresionante.

Biológicamente, se suele aceptar que el conocimiento está más relacionado con las conexiones entre neuronas que con las propias neuronas (Alkon, 1989;

Shepherd, 1990); es decir, el conocimiento se encuentra distribuido por las sinapsis de la red. Este tipo de representación distribuida del conocimiento implica que si una sinapsis resulta dañada, no perdemos más que una parte muy pequeña de la información. Además, los sistemas neuronales biológicos son redundantes, de modo que muchas neuronas y sinapsis pueden realizar un papel similar; en definitiva, el sistema resulta tolerante a fallos. En este sentido, sabemos que cada día mueren miles de neuronas en nuestro cerebro, y sin embargo tienen que pasar muchos años para que se resientan nuestras capacidades. De forma análoga, en el caso de las RNA se puede considerar que el conocimiento se encuentra representado en los pesos de las conexiones entre neuronas.

El tipo de representación de la información que manejan las RNA tanto en los pesos de las conexiones como en las entradas y salidas de información es numérica. Por ejemplo, un dato de entrada puede consistir en un valor real continuo como la edad de una persona o puede consistir en un valor numérico discreto o binario como el sexo de una persona codificado, por ejemplo, mediante: 0 = hombre, 1 = mujer.

En síntesis, podemos decir que las RNA se inspiran en la estructura del sistema nervioso, con la intención de construir sistemas de procesamiento de la información paralelos, distribuidos y adaptativos que pueden presentar un cierto comportamiento inteligente (Martín del Brío y Sanz, 1997).

Estas características contrastan con la estructura y funcionamiento de un ordenador convencional. Este tipo de computadores son máquinas construidas en torno a un único procesador (hardware) que ejecuta de un modo secuencial (paso a paso) un programa (software) almacenado en su memoria. Siguiendo este esquema, los ordenadores convencionales pueden realizar importantes operaciones de cálculo y razonamiento lógico, de forma mucho más rápida y eficiente que el cerebro. Sin embargo, existen problemas de difícil solución para un ordenador convencional que el cerebro resuelve eficazmente (Hertz, Krogh y Palmer, 1991). Precisamente estos problemas son los relacionados con el mundo real, los cuales están caracterizados por un alto grado de complejidad, imprecisión e incertidumbre como es el caso de la toma de decisiones, el reconocimiento de patrones como el habla, imágenes o caracteres escritos, etc..


### La neurona artificial

Las neuronas biológicas (figura 1) se caracterizan por su capacidad de comunicarse. Las dendritas y el cuerpo celular de la neurona reciben señales de entrada excitatorias e inhibitorias de las neuronas vecinas; el cuerpo celular las combina e integra y emite señal

les de salida. El axón transporta esas señales a los terminales axónicos, que se encargan de distribuir información a un nuevo conjunto de neuronas. Por lo

general, una neurona recibe información de miles de otras neuronas y, a su vez, envía información a miles de neuronas más.

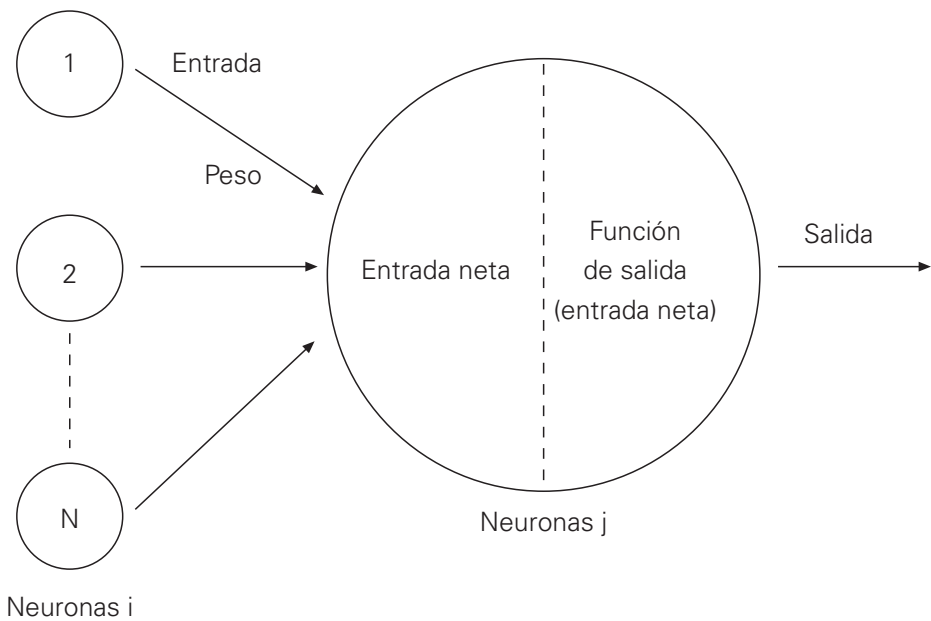
**Figura 1. Estructura general de una neurona biológica.**



Por su parte, la neurona artificial pretende mimetizar las características más importantes de la neurona biológica. En general, recibe las señales de entrada de las neuronas vecinas ponderadas por los pesos de las conexiones. La suma de estas señales ponderadas proporciona la entrada total o neta de la neurona y, mediante la aplicación de una función matemática —

denominada función de salida—, sobre la entrada neta, se calcula un valor de salida, el cual es enviado a otras neuronas (figura 2). Tanto los valores de entrada a la neurona como su salida pueden ser señales excitatorias (cuando el valor es positivo) o inhibitorias (cuando el valor es negativo).

**Figura 2. Funcionamiento general de una neurona artificial.**



## Arquitecturas

Las neuronas que componen una RNA se organizan de forma jerárquica formando capas. Una capa o nivel es un conjunto de neuronas cuyas entradas de información provienen de la misma fuente (que puede ser otra capa de neuronas) y cuyas salidas de información se dirigen al mismo destino (que puede ser otra capa de neuronas). En este sentido, se distinguen tres tipos de capas: la capa de entrada recibe la información del exterior; la o las capas ocultas son aquellas cuyas entradas y salidas se encuentran dentro del sistema y, por tanto, no tienen contacto con el exterior; por último, la capa de salida envía la respuesta de la red al exterior.

En función de la organización de las neuronas en la red formando capas o agrupaciones podemos encontrarnos con dos tipos de arquitecturas básicas: redes multicapa y redes monocapa.

Las redes multicapa disponen de conjuntos de neuronas agrupadas en dos o más capas. En la mayoría de casos, este tipo de redes están formadas por una capa de entrada, una capa de salida y una o más capas intermedias u ocultas; donde la información se transmite desde la capa de entrada hasta la capa de salida y donde cada neurona está conectada con todas las neuronas de la siguiente capa (en la figura 4 se muestra un ejemplo de red multicapa). Las redes multicapa se suelen utilizar en tareas denominadas heteroasociativas. De lo que se trata es que la red aprenda parejas de datos, de forma que cuando se presenta cierta información de entrada A, deberá responder generando la correspondiente salida asociada B. Por tal motivo, las redes que llevan a cabo este tipo de tareas también reciben el nombre de redes heteroasociativas ya que intentan asociar pares de informaciones distintas. Este tipo de redes son útiles para la clasificación de patrones —ya que, en este caso, se asocia el ejemplo con la clase o categoría a la que pertenece—, y la aproximación de funciones —donde se asocia una información de entrada con otra información de salida.

El tipo de arquitectura multicapa descrito se denomina perceptrón multicapa y ha sido el más ampliamente utilizado en el campo aplicado. La utilidad del perceptrón multicapa reside en su habilidad para operar como aproximador universal de funciones, es decir, este tipo de redes pueden aprender virtualmente cualquier relación entre un conjunto de variables de entrada y salida. Esta habilidad es el resultado de la adopción, por parte de las neuronas de la capa oculta, de una función de salida no lineal (Rumelhart y McClelland, 1986; Masters, 1993; Smith, 1993; Rzepoluck, 1998). Por su parte, el análisis discriminante lineal derivado de la estadística clásica no posee la capacidad de calcular funciones no lineales y, por tanto, pre-

sentará un rendimiento inferior frente al perceptrón multicapa en tareas de clasificación que impliquen relaciones no lineales complejas.

Por su parte, las redes monocapa están organizadas, como el propio nombre indica, en una sola capa de neuronas (en la figura 5 se muestra un ejemplo de red monocapa). Cada neurona está conectada con todas las demás que forman la arquitectura. Este tipo de redes se suelen utilizar en tareas denominadas autoasociativas. Para ello, se almacena en los pesos de la red ciertas informaciones mediante una etapa de entrenamiento. Posteriormente, cuando se presenta una información a la entrada de la red, ésta responde proporcionando la información más parecida de las almacenadas. Por tal motivo, las redes que llevan a cabo este tipo de tareas también reciben el nombre de redes autoasociativas ya que intentan asociar una información consigo misma. Este tipo de redes son útiles para regenerar informaciones de entrada, por ejemplo imágenes, que se presentan a la red incompletas o distorsionadas.

## Aprendizaje

Como hemos visto, el conocimiento de una RNA se encuentra distribuido en los pesos de las conexiones entre las neuronas que forman la red. Todo proceso de aprendizaje implica cierto número de cambios en estas conexiones. En realidad, puede decirse que se aprende modificando los valores de los pesos de la red en respuesta a un conjunto de ejemplos denominado grupo de entrenamiento. Actualmente existen muchos criterios para modificar los pesos de la red y así conseguir que aprenda a solucionar un determinado problema; estos criterios se denominan, de forma genérica, reglas de aprendizaje. Las reglas de aprendizaje consisten generalmente en algoritmos matemáticos que pueden llegar a ser sumamente complejos. Se suelen considerar dos tipos de reglas de aprendizaje: aprendizaje supervisado y aprendizaje no supervisado.

En el aprendizaje supervisado hay un “profesor” o supervisor que controla el proceso de aprendizaje de la red. El supervisor comprueba la salida de la red en respuesta a una determinada entrada y en el caso de que la salida no coincida con la deseada, se procede a modificar los pesos de las conexiones, con el fin de conseguir que la salida obtenida se aproxime a la deseada. Este tipo de aprendizaje es muy útil para la clasificación de patrones y para la aproximación de funciones.

Con el aprendizaje no supervisado también denominado autoorganizado, la red no requiere influencia de un “profesor” para ajustar los pesos de las conexiones entre sus neuronas. La red no recibe ninguna información por parte del entorno que le indique si la

salida generada en respuesta a una determinada entrada es o no correcta. Su función consiste en encontrar las características, regularidades o categorías que se puedan establecer entre los datos que se presentan en su entrada. Este tipo de aprendizaje se suele utilizar en tareas autoasociativas y en la agrupación de datos en función de su similitud.

Una vez obtenidos y guardados los pesos óptimos en la fase de entrenamiento, debemos medir la eficacia de la red de forma objetiva mediante la presentación de casos nuevos (diferentes a los casos de entrenamiento), de forma que a la fase de entrenamiento le debe seguir una fase de test. En esta fase no se modifican los pesos, simplemente se presentan casos nuevos —llamados casos de test—, a la entrada de la red y ésta proporciona una salida para cada uno de ellos. Si se comprueba que se siguen obteniendo resultados dentro del margen de error deseado, se puede proceder a emplear la RNA dentro de su entorno de trabajo real.

En la metodología de las RNA, con el fin de encontrar la red que tiene la mejor ejecución con casos nuevos —es decir, que sea capaz de generalizar—, la muestra de datos es a menudo subdividida en tres grupos (Masters, 1993; Bishop, 1995; Ripley, 1996; Martín del Brío y Sanz, 1997; Sarle, 1998): entrenamiento, validación y test.

Durante el proceso de entrenamiento o aprendizaje de una red neuronal supervisada, del tipo perceptrón multicapa, los pesos son modificados de forma iterativa de acuerdo con los valores del grupo de entrenamiento, con el objeto de minimizar el error cometido entre la salida obtenida por la red y la salida deseada por el usuario. De forma característica, en las primeras fases del aprendizaje la red se va adaptando progresivamente al conjunto de datos de entrenamiento, acomodándose al problema y favoreciendo la generalización. Así, se puede observar que el error que comete la red ante los datos de entrenamiento va descendiendo paulatinamente hasta alcanzar un valor mínimo. Sin embargo, a partir de un momento dado el sistema puede comenzar a ajustarse demasiado a las particularidades irrelevantes (ruido) presentes en los patrones de entrenamiento en vez de ajustarse a la función subyacente que relaciona entradas y salidas. Llegados a este punto se dice que la red ha sufrido un sobreentrenamiento o sobreaprendizaje, perdiendo su habilidad de generalizar su aprendizaje a casos nuevos.

Con el fin de evitar el problema del sobreentrenamiento, que puede darse en las redes del tipo perceptrón multicapa, es aconsejable utilizar un segundo grupo de datos diferentes a los de entrenamiento, denominado grupo de validación, que permita controlar el proceso de aprendizaje. De este modo, a lo largo del aprendizaje la red va modificando los pesos en función de los datos de entrenamiento y de forma

alternada se va obteniendo el error que comete la red ante los datos de validación. Esto permite estimar el error de generalización de la red —es decir, el error que se comete ante patrones diferentes a los utilizados en el entrenamiento—, a partir del error que comete ante los patrones de validación (error de validación) a lo largo del proceso de aprendizaje. Normalmente, en las primeras fases del entrenamiento el error de validación va disminuyendo progresivamente hasta un punto a partir del cual este error comienza a aumentar, ese punto indica que la red empieza a aprender las particularidades del grupo de entrenamiento —se produce el sobreentrenamiento. Una práctica común, con el fin de evitar el sobreentrenamiento, consiste en detener el aprendizaje cuando el error de validación alcanza el punto mínimo.

La utilización de un grupo de validación también permite afinar los parámetros de la red, por ejemplo, para seleccionar el número óptimo de unidades ocultas. Así, la arquitectura que obtenga el menor error de validación será la seleccionada.

El error que se obtiene ante los datos de validación proporciona una estimación sesgada del error de generalización de la red seleccionada ya que, aunque indirectamente, el grupo de validación ha intervenido en el entrenamiento. Por tanto, si se desea medir de una forma completamente objetiva la eficacia final del sistema construido, se debe contar con un tercer grupo de datos independiente, denominado grupo de test. El error que comete la red entrenada ante los datos de test proporciona una estimación insesgada del error de generalización. Finalmente, si se comprueba que se siguen obteniendo resultados satisfactorios con el grupo de test, se puede proceder a emplear el modelo dentro de su entorno de trabajo real.

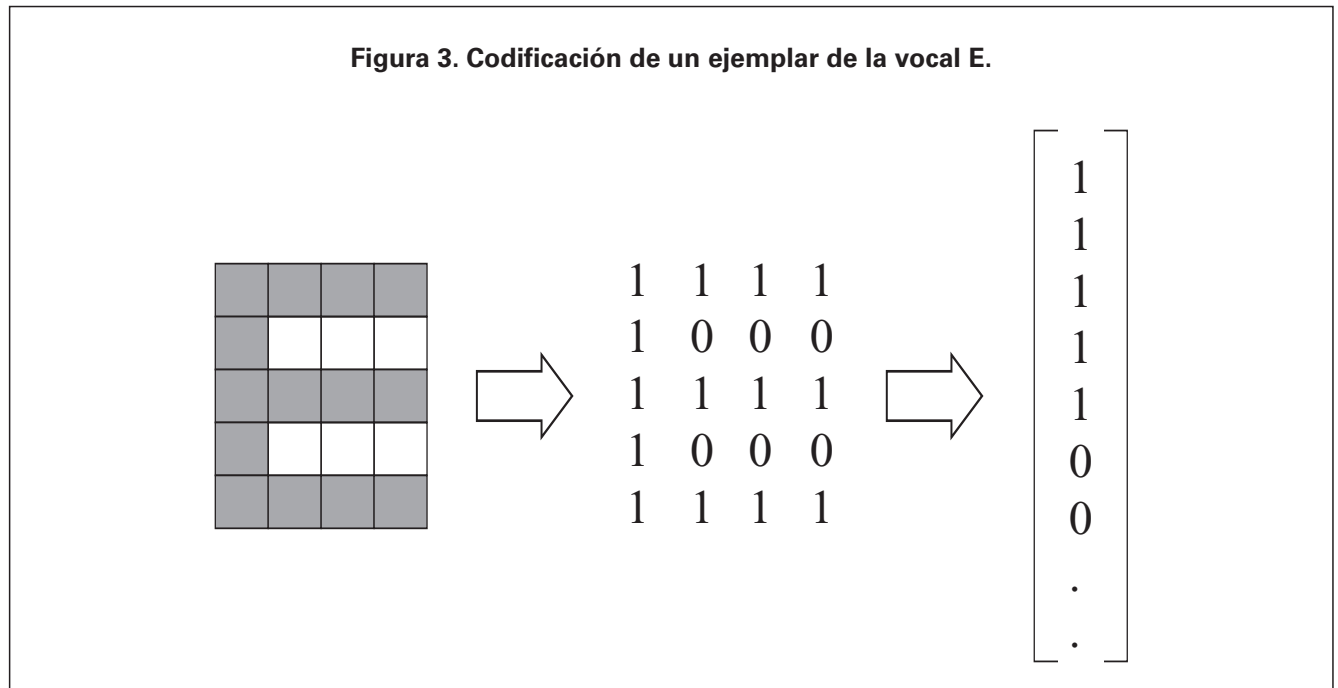
## Un ejemplo

Con el fin de ilustrar el proceso de entrenamiento y de test de una red, a continuación expondremos un ejemplo sencillo de reconocimiento de patrones. Más concretamente, se pretende que la red neuronal aprenda a reconocer las figuras de las cinco vocales. Diseñaremos dos tipos de redes neuronales, una llevará a cabo una tarea heteroasociativa, la otra realizará una tarea autoasociativa.

Debido a que las RNA son sistemas adaptativos que aprenden a partir de ejemplos, éstos deben ser representativos de lo que sucede en la realidad. En nuestro caso, tendremos que diseñar diferentes tipos de figuras para cada vocal en función de parámetros tales como el tamaño, posición y estilo de letra. Esto facilitará la capacidad de generalización de la red para responder ante patrones diferentes a los utilizados en el entrenamiento.

La primera tarea que debemos realizar, una vez diseñados los ejemplares o patrones, consiste en tratar las informaciones de forma que la red pueda procesarlas. Recordemos que el tipo de información que maneja una RNA es de tipo numérica: continua o discreta. Pues bien, en el ejemplo que nos ocupa podemos representar las figuras de las vocales mediante un cierto número de píxeles (contracción de los vocablos *picture elements*, o elementos de imagen). Con

el fin de simplificar el problema, imaginemos que queremos representar cada figura mediante una matriz de 5x4 píxeles. Los píxeles negros pueden representarse mediante el valor binario 1 y los blancos con el valor 0. Para cada figura obtendremos un vector de 1s y 0s formado a partir de la configuración de los 20 píxeles resultantes. En la figura 3 se muestra el proceso de codificación de un ejemplar de la vocal E.



Podemos estar interesados en entrenar la red para clasificar cada figura en la categoría a la que pertenece. En este caso la red debe aprender a asociar cada figura con la vocal que representa (heteroasociación). El tipo de arquitectura que se suele utilizar en este tipo de problemas consiste en un perceptrón multicapa compuesto por una capa de entrada, una oculta y una de salida. El número de neuronas de entrada y de salida estará determinado por el problema. Así, la capa de entrada a la red estará formada por tantas neuronas de entrada como elementos o píxeles formen las figuras; en este caso tenemos 20 píxeles. Cada una de estas neuronas de entrada se encargará de recibir y procesar un píxel. La capa de salida estará formada por tantas neuronas como categorías o clases contenga el problema; en este caso tenemos cinco vocales. Cada neurona de salida representará una vocal. Podemos determinar la salida de la red de forma que ante la presentación de un ejemplar, la neurona de salida correspondiente a la vocal que representa el ejemplar, dé como salida el valor 1 (activada) y todas las demás den como salida el valor 0 (desactivada). Así, si la figura que presentamos a la entrada de la red es una A, entonces la salida de la red debería ser el vector 1 0 0

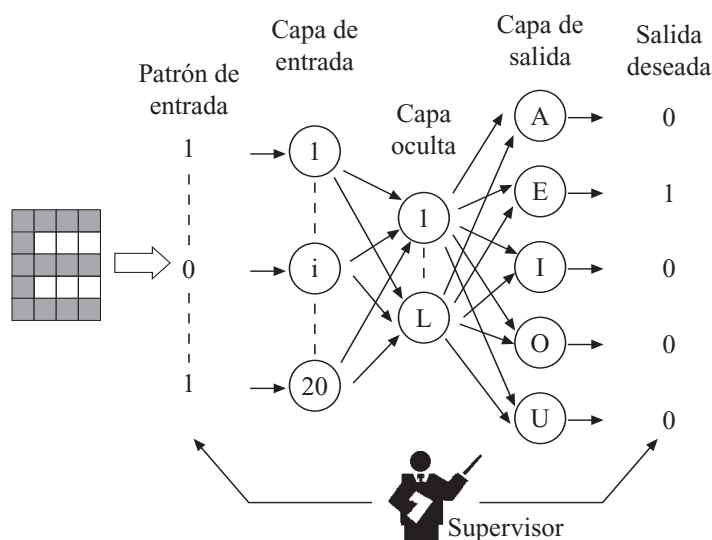
0 0; si el ejemplar es una E, entonces la salida debería ser el vector 0 1 0 0 0; y así sucesivamente. Por último, el número de neuronas ocultas dependerá, en gran medida, de la complejidad del problema.

La fase de entrenamiento o aprendizaje consistirá en la presentación repetida de un grupo representativo de ejemplos de vocales junto con sus salidas correspondientes. La regla de aprendizaje será supervisada, debido a que cada información de entrada está asociada a una salida deseada. Mediante esta regla iremos modificando los pesos de las conexiones iterativamente hasta que la salida de la red coincida o se aproxime hasta un nivel aceptable a la salida deseada para cada uno de los ejemplos de entrenamiento. En la figura 4A se muestra este proceso para el caso de un ejemplar de la vocal E. En esta fase, la red organiza una representación interna del conocimiento en los pesos de las conexiones de las neuronas ocultas, a fin de aprender la relación que existe entre el conjunto de patrones dados como ejemplo y sus salidas correspondientes.

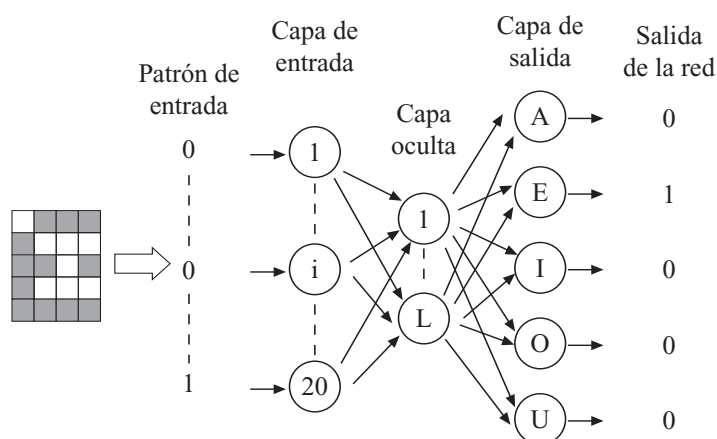
En la fase de test podremos presentar ejemplares nuevos, la red propagará la información a través de las sucesivas capas hasta proporcionar una salida. La pre-

**Figura 4. Entrenamiento y test de un perceptrón multicapa supervisado para la clasificación de las vocales.**

*A) Fase de entreno:*



*B) Fase de test:*




sentación de ejemplares desconocidos, distorsionados o incompletos nos permitirá comprobar el grado de generalización que alcanza el modelo construido. En la figura 4B se muestra cómo la red proporciona una respuesta correcta ante un ejemplar incompleto de la vocal E que no había sido utilizado en la fase de entrenamiento.

Hemos visto un ejemplo de reconocimiento de patrones mediante la clasificación de cada figura en la categoría a la que pertenece. Se trata de un caso de red heteroasociativa. Ahora bien, podríamos estar interesados en entrenar la red para que aprendiera a asociar cada patrón o figura consigo misma. Como hemos visto, se trataría de un ejemplo de reconocimiento de patrones por autoasociación. Con fines ilus-

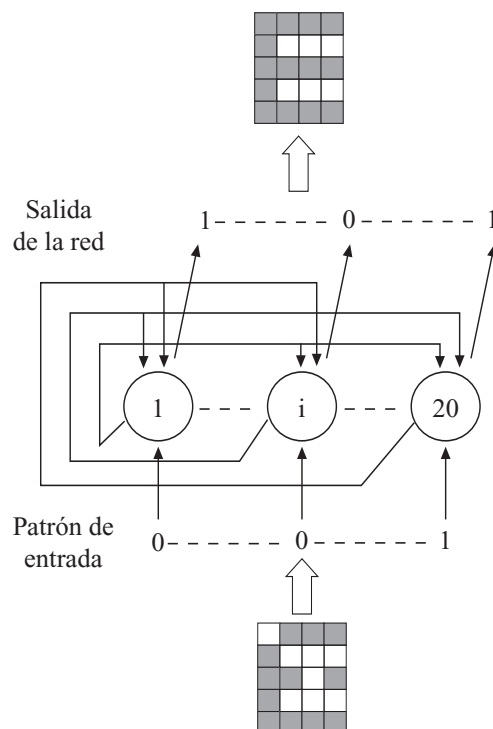
trativos, utilizaremos una red monocapa entrenada con aprendizaje no supervisado para realizar esta tarea, aunque en la práctica es más efectivo utilizar una red multicapa con aprendizaje supervisado. El número de neuronas de la red monocapa estará determinado por el número de píxeles que componen las figuras, en este caso es igual a 20; de forma que cada neurona se encargará de recibir y procesar un píxel. La fase de aprendizaje consistirá en el almacenamiento de los diferentes ejemplos de entrenamiento en los pesos de la red. Para ello, iremos presentando los ejemplos o patrones y la red irá modificando los pesos de forma iterativa hasta que alcancen una estabilidad. En la figura 5A se muestra este proceso para el caso de un ejemplar de la vocal E.

**Figura 5. Entrenamiento y test de una red monocapa no supervisada para la reconstrucción de las vocales.**

*A) Fase de entreno:*



*B) Fase de test:*



En la fase de test se demuestra la utilidad de este tipo de modelos. Permiten la reconstrucción de una determinada información de entrada que se presenta incompleta o distorsionada, proporcionando como salida la información almacenada más parecida. En la figura 5B se muestra cómo la red reconstruye en su salida la figura de una E a partir de su entrada incompleta.

### **Ventajas y limitaciones de las redes neuronales artificiales**

Las RNA no son la panacea que permite resolver todos los problemas, sino que están orientadas a un determinado tipo de tareas. Podemos destacar cuatro características del problema o tarea que hacen aconsejable la utilización de las RNA (Martín del Brío y Sanz, 1997). Por una parte, no se dispone de un conjunto de reglas sistemáticas que describan completamente el problema. En cambio, sí disponemos de muchos ejemplos o casos (condición indispensable para poder aplicar las RNA). Por otra parte, los datos procedentes del problema son imprecisos, incoherentes o con ruido (como el ejemplo visto sobre el reconocimiento de la letra E). Por último, el problema es de elevada dimensionalidad, es decir, el número de

variables de entrada es demasiado grande como para que un modelo convencional aprenda a solucionar el problema en un tiempo razonable.

Cuando no se dan estas circunstancias puede ser más aconsejable optar por solucionar el problema mediante un modelo derivado de la estadística o la Inteligencia Artificial. Por tanto, no debemos concebir las RNA como una alternativa, sino más bien como un complemento a los modelos convencionales ya establecidos.

Las RNA presentan una serie de ventajas frente a los modelos estadísticos. Una ventaja fundamental consiste en que los modelos neuronales normalmente no parten de restricciones respecto de los datos de partida (tipo de relación funcional entre variables), ni suele imponer presupuestos (como distribución gaussiana u otras). Por otra parte, como hemos comentado, la habilidad de las neuronas de calcular funciones de salida no lineales capacita a la red para resolver problemas complejos o no lineales. De este modo, en numerosas aplicaciones se están consiguiendo con RNA cotas de error mucho mejores que las proporcionadas por la estadística.

Respecto a las limitaciones que presentan las RNA, una de las más importantes consiste en que es difícil comprender la naturaleza de las representaciones internas generadas por la red para responder ante un



problema determinado. Es decir, no sabemos cómo el sistema interrelaciona las diferentes variables de entrada con los pesos de las conexiones entre neuronas para elaborar una solución (Rzempoluck, 1998). Esta limitación contrasta con los diferentes modelos estadísticos, los cuales permiten observar los parámetros o pesos relativos que el modelo otorga a cada una de las variables que intervienen en el modelo.

Con el fin de solventar esta limitación y así determinar qué es lo que la red ha aprendido, algunos autores (por ejemplo, Lisboa, Mehridehnavi y Martin, 1994) hacen uso de matrices de sensibilidad, las cuales permiten cuantificar la importancia que tiene cada variable de entrada sobre cada variable de salida de la red.

## Realización de redes neuronales artificiales

La realización más simple e inmediata consiste en simular la red sobre un ordenador convencional mediante un software específico. Aunque de esta manera se pierde su capacidad de cálculo en paralelo, las prestaciones que ofrecen los ordenadores actuales resultan suficientes para resolver numerosos problemas prácticos, al permitir simular redes de tamaño considerable a una velocidad razonable. Esta constituye la manera más barata y directa de realizar una RNA. Por otra parte, no es necesario que cada investigador diseñe sus propios simuladores, pues existen numerosas aplicaciones comerciales que permiten la simulación de multitud de modelos neuronales (Hilera y Martínez, 1995; Martín del Brío y Sanz, 1997). Para consultar un listado actualizado de productos comerciales y de libre distribución, se recomienda visitar en internet el FAQ (*Frequent Asked Questions*) del grupo de noticias sobre RNA editado por Sarle (Sarle, 1998).

La alternativa a la simulación software en un ordenador, consiste en llevar a cabo la emulación hardware de la red neuronal, mediante el uso de procesadores especialmente diseñados para el trabajo con redes neuronales o mediante el diseño de circuitos específicos que reflejan con cierta fidelidad la arquitectura de la red (Hilera y Martínez, 1995; Martín del Brío y Sanz, 1997).

## Aplicaciones generales

Las RNA son una tecnología computacional emergente que puede utilizarse en un gran número y variedad de aplicaciones. A continuación, proporcionamos un listado de aplicaciones de RNA en diferentes campos (McCord Nelson y Illingworth, 1991; Hilera y Martínez, 1995; Buscema, 1997):

### –Biología

- Estudio del cerebro
- Obtención de modelos de retina

### –Empresa

- Identificación de candidatos para posiciones específicas
- Reconocimiento de caracteres escritos
- Predicción del rendimiento económico de las empresas

### –Medio ambiente

- Previsión del tiempo

### –Finanzas

- Previsión de la evolución de los precios
- Valoración del riesgo de los créditos
- Identificación de firmas

### –Manufacturación

- Robots automatizados y sistemas de control (visión artificial y sensores de presión, temperatura, gas, etc.)
- Control de producción en líneas de proceso

### –Medicina

- Diagnóstico y tratamiento a partir de síntomas y/o de datos analíticos (electrocardiograma, encefalograma, análisis sanguíneo, cuestionarios, etc.)
- Monitorización en cirugía
- Predicción de reacciones adversas a los medicamentos
- Lectores de rayos X

### –Militares

- Clasificación de las señales de radar
- Creación de armas inteligentes
- Reconocimiento y seguimiento de tiro al blanco
- Detección de bombas

### –Psicología y Psiquiatría

- Modelización de procesos psicológicos básicos
- Reconocimiento del habla (análisis e interpretación de frases habladas)
- Diagnóstico de diversos trastornos (demencia, epilepsia, alcoholismo, etc.) en función de señales EEG
- Clasificación de las fases del sueño
- Diagnóstico psicológico
- Predicción de rendimiento académico

## REDES NEURONALES ARTIFICIALES APLICADAS A LA CONDUCTA ADICTIVA

En los apartados anteriores hemos visto que las RNA constituyen un modelo de procesamiento de la información robusto para la solución de problemas

complejos relacionados principalmente con el reconocimiento de patrones: clasificación, predicción y reconstrucción de ejemplares. Esta herramienta tecnológica ha sido aplicada muy recientemente en el campo de las adicciones. En este sentido, el Centro de Investigación Semeion de las Ciencias de la Comunicación (Roma, Italia), fundado y dirigido por Massimo Buscema, ha sido pionero en la aplicación de las RNA con el fin de prevenir y predecir la conducta adictiva. Los investigadores de dicho centro han construido diferentes modelos de red, los cuales pueden dividirse, siguiendo el esquema expuesto anteriormente, en dos grandes grupos: redes heteroasociativas y redes autoasociativas. Vamos a examinar cómo han aplicado estos dos tipos de redes al problema de las adicciones.

Buscema (1995) ha desarrollado un nuevo enfoque, denominado *Squashing Theory*, basado en el registro de un grupo de medidas biológicas, psicológicas y sociológicas con el fin de predecir, mediante un perceptrón multicapa supervisado, la conducta adictiva del sujeto. Más concretamente, se trata de entrenar una red para clasificar a los sujetos en dos posibles categorías, adicto (salida de la red = 1) o no adicto (salida de la red = 0), al presentarle a su entrada una serie de medidas obtenidas mediante cuestionario, susceptibles de ser predictoras del consumo de droga.

A continuación, se presentan las áreas específicas que deben ser evaluadas para la predicción de la conducta adictiva, de acuerdo con los principios de la *Squashing Theory* (Buscema, 1995):

- a) Características académicas
- b) Ocupación
- c) Características y micro vulnerabilidad del padre, madre y hermanos
- d) Condiciones de vida
- e) Características sexuales y características de la pareja
- f) Creencias religiosas
- g) Estatus económico y gastos
- h) Micro vulnerabilidad y estilo de vida relacionada con el alcohol y tabaco (no con adicción a drogas)
- i) Problemas con la justicia
- j) Amistades
- k) Uso del tiempo libre
- l) Características psicológicas
- m) Micropercepciones de la familia y la pareja

Siguiendo este enfoque, Buscema (1995) seleccionó una muestra compuesta por tres grupos de sujetos. El primer grupo, 47 sujetos, se caracterizaba por estar recibiendo tratamiento por su adicción a la heroína. El segundo grupo, 94 sujetos, actuaba como grupo

control y no había tenido ningún problema con las drogas. Estos dos grupos fueron etiquetados como casos prototípicos. Por último, el tercer grupo, 47 sujetos, estaba formado por sujetos que habían sido adictos a la heroína y habían dejado el tratamiento hacía al menos cinco años; por tal motivo, fueron etiquetados como casos inciertos. Para cada sujeto se registraron y codificaron numéricamente las variables de interés, determinándose su actual estatus de adicto o no a la heroína. La muestra total fue dividida aleatoriamente en casos de entrenamiento y casos de test. Obtenidos los pesos óptimos de la red neuronal a partir de los casos de entrenamiento, se comprobó la capacidad de predicción del modelo mediante la presentación de los casos de test. La red fue capaz de clasificar correctamente, en adicto o no adicto, el 92% de los casos prototípicos y el 80% de los casos inciertos.

Posteriormente, Buscema, Intraligi y Bricolo (1998) compararon el rendimiento de ocho modelos diferentes de red multicapa supervisada para la clasificación de los sujetos según su adicción o no a las drogas. Para ello, se usó una muestra compuesta por 223 sujetos adictos a la heroína y 322 sujetos control. La mitad de la muestra se utilizó para entrenar los diferentes modelos de red, la otra mitad sirvió para testar su rendimiento. La capacidad predictiva de los ocho modelos fue siempre superior al 91% en los casos de test, llegando a alcanzar, en algunos casos, el 97%.

Por su parte, Speri, Schilirò, Bezzetto et al. (1998) aplicaron los principios de la *Squashing Theory* al ámbito militar. Para ello, contaron con una muestra de 170 soldados compuesta por tres submuestras: 32 sujetos calificados de "normales", 24 sujetos altamente problemáticos y 114 sujetos con presunta o declarada adicción a las drogas. Se construyeron varias redes a partir de una configuración diferente de casos de entrenamiento y test. Todos los modelos mostraron unos resultados estables clasificando correctamente, en toxicómano o normal, al menos el 94% de los casos de test. Posteriormente, se compararon las respuestas de las redes neuronales con las de una evaluación clínica estándar; el nivel de acuerdo fue superior al 70% para los 170 casos.

Maurelli y Di Giulio (1998) compararon siete modelos diferentes de red neuronal para la predicción del grado de alcoholismo. La muestra estaba compuesta por 91 alcohólicos "moderados" y 22 alcohólicos "serios" que posteriormente fue dividida en casos de entrenamiento y test. El propósito de las redes consistía en dar como respuesta si el sujeto era alcohólico "moderado" o "serio" a partir de la entrada de cinco variables que representaban los resultados de varios tests biomédicos. Los resultados, a partir de los casos de test, fueron variados oscilando la capacidad de predicción de los modelos entre el 73 y el 86%. Posteriormente, se creó una nueva red, denominada

MetaNet, a partir de los cuatro modelos que habían obtenido mejores resultados. El modelo MetaNet alcanzó una capacidad de predicción del 93%.

Hasta ahora, hemos revisado los trabajos realizados por el equipo de Buscema sobre la utilización de redes neuronales heteroasociativas para la clasificación y/o predicción de la conducta adictiva.

Este equipo también ha utilizado modelos de red autoasociativa en el campo de las adicciones, creando recientemente una red autoasociativa, denominada red de satisfacción de restricciones (Rumelhart y McClelland, 1986), con el objeto de extraer los rasgos característicos relacionados con el consumo de droga. El aprendizaje de este tipo de red, compuesta por dos capas de igual tamaño —entrada y salida—, consiste en ir presentando en la capa de entrada los datos referidos a un grupo de sujetos —toxicómanos y no toxicómanos—, y en modificar los pesos de las conexiones de forma supervisada hasta que la capa de salida proporcione una información igual o similar a la presentada a su entrada. Los datos que se presentan a la red harán referencia a las variables o características predictoras propuestas por la *Squashing Theory* y el estatus del sujeto como adicto o no. Ya vimos un proceso parecido en el almacenamiento de las vocales mediante una red monocapa no supervisada.

Una vez determinados los pesos de la red autoasociativa, podemos preguntar a la red qué rasgos prototípicos poseen los sujetos que pertenecen, por ejemplo, al grupo de toxicómanos (Buscema, Intraligi y Bricolo, 1998). Para ello, presentaremos como entrada el valor 0 (desactivado) para todas las neuronas que representan las diversas características del sujeto, excepto la neurona que representa el estatus de toxicómano; en este caso le presentamos el valor 1 (activado). La red proporcionará como salida los valores característicos de los sujetos toxicómanos para cada una de las variables predictoras.

Massini y Shabtay (1998) aplicaron este modelo de red en un centro de desintoxicación con metadona. A partir de una muestra compuesta por 69 pacientes del centro, la red neuronal permitió extraer las características prototípicas de los sujetos que había seguido con éxito el tratamiento de desintoxicación y los que no. Este procedimiento puede ser de gran utilidad ya que permite averiguar qué tratamiento será más adecuado en función del perfil del sujeto.

Para finalizar revisaremos los trabajos de un equipo de investigadores centrado en la predicción del alcoholismo a partir de respuestas psicofisiológicas. Así, Klöppel (1994) llevó a cabo un estudio preliminar con tres sujetos alcohólicos y tres sujetos control. A partir de la selección de dos sujetos de cada grupo, entrenó una red neuronal para clasificar los Potenciales Evocados (PE), previamente codificados numéricamente, de los sujetos en dos categorías: PE procedente de un

sujeto alcohólico o PE procedente de un sujeto control. Los PE de los dos sujetos restantes actuaron como grupo de test. La red clasificó correctamente el 55.6% de los PE procedentes del sujeto alcohólico y el 89.4% de los PE procedentes del sujeto no alcohólico. Aunque los resultados no son muy buenos, el estudio muestra que la clasificación de los PE mediante una red neuronal es posible.

Recientemente, Winterer y sus colaboradores (Winterer, Klöppel, Heinz et al., 1998; Winterer, Ziller, Klöppel et al., 1998) se propusieron comprobar si a partir de los patrones electroencefalográficos cuantitativos (QEEG) se puede predecir, utilizando una red neuronal, la recaída de los sujetos alcohólicos al inicio del tratamiento. Se contó con una muestra de 78 pacientes alcohólicos que habían iniciado un tratamiento de desintoxicación. Se registraron los patrones QEEG de los sujetos siete días después de iniciado el tratamiento, determinándose tres meses más tarde dos posibles estatus: sujeto con recaída (49 sujetos) o sujeto abstinentes (29 sujetos). Se entrenó un perceptrón multicapa supervisado para predecir si el sujeto había recaído o se había mantenido abstinentes, ante la presentación del patrón QEEG del sujeto. La red fue capaz de predecir y/o clasificar correctamente el estatus del 85% de los casos de test. Con el objeto de comparar el rendimiento de la red con un modelo estadístico clásico, se aplicó el análisis discriminante lineal sobre las mismas variables. Este modelo clasificó correctamente el 75% de los casos de test. La aplicación del análisis discriminante no lineal (con polinomios de segundo orden) no mejoró este resultado. Aunque la red neuronal exhibió un rendimiento superior frente al análisis discriminante, estos resultados deben ser tomados con precaución debido al reducido número de sujetos con el cual se trabajó.

## CONCLUSIONES

La primera parte de este trabajo ha pretendido ser una introducción general sobre el campo de las RNA evitando, de forma intencionada, la presentación de fórmulas matemáticas complejas —muy habituales incluso en documentos introductorios—, que no haría más que diezmar el número de lectores potenciales. Así, las RNA se presentan como una tecnología emergente de suma utilidad para la solución de problemas complejos en multitud de campos del conocimiento.

La segunda parte se ha centrado en la revisión de los trabajos que han aplicado los modelos de RNA en el no menos complejo campo de las adicciones. Los resultados obtenidos en los diferentes trabajos revisados confirman el papel de las RNA como una nueva y eficaz metodología para la descripción, prevención y predicción de la conducta adictiva. Así, hemos visto

que las redes heteroasociativas pueden predecir el estatus del sujeto como adicto o no adicto con un margen de error pequeño, en función de una serie de respuestas a un cuestionario. Por su parte, las redes autoasociativas permiten extraer los rasgos característicos de los sujetos adictos y no adictos, así como averiguar qué tratamiento será el más adecuado en función del perfil del sujeto. Aunque tales trabajos pueden ser calificados de preliminares, constituyen el punto de partida de futuras investigaciones que permitirán determinar el papel de las RNA en la predicción de la conducta adictiva. Así, se hace necesario realizar estudios comparativos respecto a los modelos estadísticos clásicos y utilizar muestras suficientemente grandes —no sólo muestras clínicas—, para poder extrapolar los resultados a la población. Estas investigaciones también nos permitirán averiguar si los buenos resultados obtenidos hasta el momento en las diferentes áreas de conocimiento se extienden al campo de las conductas adictivas.

## REFERENCIAS BIBLIOGRÁFICAS

- Alkon, D.L. (1989). Almacenamiento de memoria y sistemas neurales. *Investigación y Ciencia*, Septiembre, 14-23.
- Arbib, M.A. (Ed.) (1995). *The handbook of brain theory and neural networks*. Cambridge, Mass.: MIT Press.
- Arbib, M.A., Erdi, P. y Szentagothai, J. (1997). *Neural organization: structure, function and dynamics*. Cambridge, Mass.: MIT Press.
- Bishop, C.M. (1995). *Neural networks for pattern recognition*. New York: Oxford University Press.
- Bonilla, M. y Puertas, R. (1997). *Análisis de las redes neuronales: aplicación a problemas de predicción y clasificación financiera*. Valencia (España): Servei de Publicacions: Universitat de València.
- Buscema, M. (1995). Squashing Theory: A prediction approach for drug behavior. *Drugs and Society*, 8(3-4), 103-110.
- Buscema, M. (1997). A general presentation of artificial neural networks. I. *Substance Use & Misuse*, 32(1), 97-112.
- Buscema, M. (1998). Artificial neural networks and complex systems. I. Theory. *Substance Use & Misuse*, 33(1), 1-220.
- Buscema, M., Intraligi, M. y Bricolo, R. (1998). Artificial neural networks for drug vulnerability recognition and dynamic scenarios simulation. *Substance Use & Misuse*, 33(3), 587-623.
- De Lillo, A. y Meraviglia, C. (1998). The role of social determinants on men's and women's mobility in Italy. A comparison of discriminant analysis and artificial neural networks. *Substance Use and Misuse*, 33(3), 751-764.
- Duncan, J.C. (1997). A comparison of radial basis function and multilayer perceptron neural networks with linear multiple regression in cohort-survival based enrollment projection (Kent State University, 1996). *Dissertation Abstracts International*, DA1-A 57/12, 4995.
- French, B.M., Dawson, M.R. y Dobbs, A.R. (1997). Classification and staging of dementia of the Alzheimer type: a comparison between neural networks and linear discriminant analysis. *Archives of Neurology*, 54(8), 1001-1009.
- Hertz, J., Krogh, A. y Palmer, R.G. (1991). *Introduction to the theory of neural computation*. Redwood City, CA: Addison-Wesley.
- Hilera, J.R. y Martínez, V.J. (1995). *Redes neuronales artificiales: Fundamentos, modelos y aplicaciones*. Madrid: Ra-Ma.
- Jang, J. (1998). Comparative analysis of statistical methods and neural networks for predicting life insurers' insolvency (bankruptcy) (The University of Texas at Austin, 1997). *Dissertation Abstracts International*, DA1-A 59/01, 228.
- Jefferson, M., Pendleton, N., Lucas, S. y Horan, M. (1997). Comparison of a genetic algorithm neural network with logistic regression for predicting outcome after surgery for patients with nonsmall cell lung carcinoma. *Cancer*, 79(7), 1338-1342.
- Klöppel, B. (1994). Classification by neural networks of evoked potentials: A first case study. *Neuropsychobiology*, 29(1), 47-52.
- Lisboa, P., Mehridehnavi, A. y Martin, P. (1994). The interpretation of supervised neural networks. pp. 11-17. En Lisboa, P. y Taylor, M. (Eds.). *Proceedings of the Workshop on Neural Network Applications and Tools*. Los Alamitos, CA: IEEE Computer Society Press.
- Martín del Brío, B. y Sanz, A. (1997). *Redes neuronales y sistemas borrosos*. Madrid: Ra-Ma.
- Massini, G. y Shabtay, L. (1998). Use of a constraint satisfaction network model for the evaluation of the methadone treatments of drug addicts. *Substance Use & Misuse*, 33(3), 625-656.
- Masters, T. (1993). *Practical neural networks recipes in C++*. London: Academic Press.
- Maurelli, G. y Di Giulio, M. (1998). Artificial neural networks for the identification of the differences between "light" and "heavy" alcoholics, starting from five nonlinear biological variables. *Substance Use & Misuse*, 33(3), 693-708.
- McCord Nelson, M. y Illingworth, W.T. (1991). *A practical guide to neural nets*. Reading, MA: Addison-Wesley.
- Pazos, A. (Ed.) (1996). *Redes de neuronas artificiales y algoritmos genéticos*. A Coruña: Universidade da Coruña, Servicio de Publicacions.
- Ripley, B.D. (1996). *Pattern recognition and neural networks*. Cambridge: Cambridge University Press.
- Rumelhart, D.E. y McClelland, J.L. (Eds.). (1986). *Parallel distributed processing: explorations in the microstructure of cognition*. Cambridge, Mass.: MIT Press.
- Rzempoluck, E.J. (1998). *Neural network data analysis using Simulnet*. New York: Springer-Verlag.
- Sarle, W.S. (Ed.) (1998). *Neural network FAQ*. Periodic posting to the Usenet newsgroup comp.ai.neural-nets, URL: <ftp://ftp.sas.com/pub/neural/FAQ.html>.

- Shekharan, R.A. (1997). Modeling pavement deterioration by regression and artificial neural networks (The University of Mississippi, 1996). *Dissertation Abstracts International*, DAI-B 57/07, 4578.
- Shepherd, G.M. (1990). *The synaptic organization of the brain*. Oxford: Oxford Press.
- Simpson, P.K. (Ed.) (1995). *Neural networks technology and applications: theory, technology and implementations*. New York: IEEE.
- Smith, M. (1993). *Neural networks for statistical modeling*. New York: Van Nostrand Reinhold.
- Speri, L., Schilirò, G., Bezzetto, A., Cifelli, G., De Battisti, L., Marchi, S., Modenese, M., Varalta, F. y Consigliere, F. (1998). The use of artificial neural networks methodology in the assessment of "vulnerability" to heroin use among army corps soldiers: A preliminary study of 170 cases inside the Military Hospital of Legal Medicine of Verona. *Substance Use & Misuse*, 33(3), 555-586.
- Tommaso, M., Sciruicchio, V., Bellotti, R., Castellano, M., Tota, P., Guido, M., Sasanelli, G. y Puca, F. (1997). Discrimination between migraine patients and normal subjects based on steady state visual evoked potentials: discriminant analysis and artificial neural network classifiers. *Functional Neurology*, 12(6), 333-338.
- Vohradsky, J. (1997). Adaptive classification of two-dimensional gel electrophoretic spot patterns by neural networks and cluster analysis. *Electrophoresis*, 18(15), 2749-2754.
- Waller, N.G., Kaiser, H.A., Illian, J.B. y Manry, M. (1998). A comparison of the classification capabilities of the 1-dimensional Kohonen neural network with two partitioning and three hierarchical cluster analysis algorithms. *Psychometrika*, 63(1), 5-22.
- West, P., Brockett, P. y Golden, L. (1997). A comparative analysis of neural networks and statistical methods for predicting consumer choice. *Marketing Science*, 16(4), 370-391.
- Winterer, G., Klöppel, B., Heinz, A., Ziller, M., Dufeu, P., Schmidt, L.G. y Herrmann, W.M. (1998). Quantitative EEG (QEEG) predicts relapse in patients with chronic alcoholism and points to a frontally pronounced cerebral disturbance. *Psychiatry Research*, 78(1-2), 101-113.
- Winterer, G., Ziller, M., Klöppel, B., Heinz, A., Schmidt, L.G. y Herrmann, W.M. (1998). Analysis of quantitative EEG with artificial neural networks and discriminant analysis: A methodological comparison. *Neuropsychobiology*, 37(1), 41-48.

